BenGER：一个用于德国法律任务端到端基准测试的协作Web平台

Sebastian Nagl 慕尼黑工业大学 慕尼黑，德国 sebastian.nagl@tum.de
Matthias Grabmaier 慕尼黑工业大学 慕尼黑，德国 matthias.grabmaier@tum.de

摘要 — 评估大型语言模型（*LLM*）在法律推理中的表现需要跨越任务设计、专家标注、模型执行和基于度量的评估的工作流程。在实践中，这些步骤分散在多个平台和脚本中，限制了透明度、可复现性以及非技术性法律专家的参与。我们提出了 *BenGER*（德国法律基准测试）框架，这是一个开源的*Web*平台，集成了任务创建、协作标注、可配置的*LLM*运行以及基于词法、语义、事实和裁判模型的评估。*BenGER* 支持多配置项目，具有租户隔离和基于角色的访问控制，并可选择向标注者提供基于参考标准的形成性反馈。我们将展示一个实时部署，演示端到端的基准测试创建和分析。

关键词 — 法律自然语言处理，基准测试，大型语言模型，标注系统，法律人工智能

ACM 参考格式: Sebastian Nagl and Matthias Grabmaier. 2026. BenGER: A Collaborative Web Platform for End-to-End Benchmarking of German Legal Tasks. In *Proceedings of International Conference on Artificial Intelligence and Law (ICAIL 2026)*. ACM, New York, NY, USA, 2 pages.

1 引言与动机

法律人工智能的基准测试成本高昂且技术要求高，尤其是因为高质量的法律专业知识稀缺。在许多项目中，流程是碎片化的：专家提供材料或从现有来源获取，研究人员将其转化为基准实例，可选地在单独的工具中收集标注，通过临时脚本执行模型运行，并且评估代码在每个研究中被重新实现[1, 2]。这引入了可避免的交接，减少了专家监督，并使协作和复现变得困难。BenGER 通过提供一个统一的、基于浏览器的工作流来解决这一问题，领域专家可以从任务定义和标注到模型执行和评估进行端到端操作。

2 系统概览

BenGER 是一个生产就绪的Web应用程序，用于法律任务的端到端基准测试（最初聚焦于德国法律，但不限于司法管辖区）。它支持多种任务格式（自由文本推理、多项选择、跨度标注）、协作标注、任意LLM的批量执行以及使用广泛度量标准进行结果分析。BenGER 以开源软件形式发布，可以在本地或机构内部署，同时我们也为社区工作提供安全托管的版本。

3 支持的工作流与用例

BenGER 明确建模了完整的法律基准测试工作流，我们将在演示中展示：

1. 任务创建：法律专家直接在平台中定义任务和参考答案。
2. 标注：人工标注者使用协作式Web界面提交解决方案。
3. 形成性反馈（可选）：标注者可以接收基于LLM的反馈，将其答案与参考答案进行比较，提供建设性指导。
4. 模型执行：使用可配置的API密钥在相同任务上执行选定的LLM。
5. 评估：使用词法、语义、事实、分类和“LLM作为裁判”等度量标准对结果进行评估。
6. 分析与导出：结果可以在平台内分析或导出用于出版。

4 技术架构与安全性

BenGER 采用模块化服务架构，前端使用 Next.js (TypeScript)，后端使用 FastAPI (Python)，并由 PostgreSQL 支持。Redis 和 Celery 工作者支持模型运行和评估的可扩展后台执行。系统完全容器化，可通过 Docker Compose 或 Kubernetes 部署，并专为涉及潜在敏感法律材料的协作而设计。

租户隔离与访问控制：组织在数据层隔离，并通过基于角色的权限（例如管理员、贡献者、标注者）进行管理。项目级访问控制允许细粒度的共享，同时防止意外的跨组织数据暴露。

API密钥处理与操作边界：模型执行可按用户或项目配置，使贡献者能够在适当时使用自己的API凭证。这减少了集中式凭证管理，并有助于使使用符合机构政策。

人工监督：可选的LLM反馈可以通过提示模板设计为针对个体情境的支持性和教育性。项目可以完全禁用反馈或将其限制在特定任务和角色上，确保专家治理仍然是基准测试质量保证的主要机制。

5 定位及与现有工具的相比优势

BenGER 针对一个常见的空白：现有解决方案通常覆盖基准测试流程中的单个步骤——要么是标注/数据管理（例如 DeepWrite [3]），要么是模型评估，但没有提供一个集成的、角色感知的、领域专家无需脚本即可运行的工作流。与通用标注平台（如 LabelStudio 或 Doccano [4, 5]）相比，BenGER 在一个免费系统中增加了多组织隔离、可配置的LLM执行和标准化评估。与临时评估脚本相比，它将任务、模型配置和指标转化为可重用、可审计的工件，提高了涵盖大学、公共机构和非政府组织的团队的可复现性。

超越通用标注平台。通用的法律标注系统（例如 Lawnotation [6]）提供灵活的标注界面和数据集导出，但它们通常需要额外的基础设施来 (a) 强制多个贡献组织之间的清晰分离，(b) 连接到异构的LLM提供商，以及 (c) 使用预定义且因此一致的指标定义来执行和跟踪评估运行。BenGER 通过将本地法律任务标注与模型执行和标准化评估相结合来填补这一空白，使领域专家能够在整个生命周期中保持对任务定义、参考答案和质量保证的控制。

超越评估脚本和临时流程。在许多研究项目中，评估被实现为项目特定代码：提示模板、模型调用和指标被编码在笔记本或脚本中，难以跨组织和任务重用。BenGER 将这些步骤外部化到一个共享平台中：任务、模型配置和指标成为显式的工件，可以在不同团队之间重用、审计和比较，从而提高了可复现性并降低了上手成本。

对标注者和人工基线的益处。为了改善激励和学习价值，该平台可以选择性地向标注者提供基于参考标准的建设性反馈——这在德国法律教育中很典型（来自私人讲师“Repetitor”），突出缺失的推理步骤和常见陷阱，同时保持专家治理的控制。带有质量信号的人工基线。平台支持在标注层面进行质量监控（例如进度跟踪和一致性指标），使项目负责人能够系统地管理基线构建。在实践中，这降低了基准测试结论由噪声标注或不一致任务解释驱动的风险。

6 社区影响与可复现性

作为开源软件，BenGER 通过使任务贡献、标注、模型执行和评估均可通过浏览器访问，降低了非技术贡献者的门槛。它通过将任务定义、参考答案、模型配置和指标选择存储为可共享、可审计和可重新运行的显式工件来促进可复现性。集成层设计为可扩展，以支持新任务、模型提供者和指标。

降低公共机构和非政府组织的门槛。法律数据集通常受到能力和治理要求的限制。通过组织感知的数据分离和基于浏览器的任务创建、标注和评估工作流，BenGER 使机构能够贡献任务并获得模型性能分析，而无需将材料交给外部工程师。

可复现的评估工件。BenGER 鼓励将评估配置存储为可共享的工件：任务定义、参考答案、模型配置和所选指标。这支持透明的报告，并使跨研究团体和随时间推移重现实验结果变得更加容易。

可扩展性。指标和模型集成层设计为可增量扩展。可以添加新任务、模型提供者或评分方法，而无需重写评估流程，使该平台适用于长期的基准测试计划。

7 结论

BenGER 展示了如何通过将标注、模型评估和分析整合到一个单一平台中，使法律人工智能基准测试更加透明、协作和可访问。我们让法律专家控制整个评估流程，这使得系统支持更可靠的，并可能导致关于法律中LLM能力的可扩展研究。

8 AI使用声明

我们使用 OpenAI GPT-5 进行手稿的 LaTeX、语法和拼写任务，以及使用 Anthropic Claude Sonnet 4、Claude Opus 4 和 Google Gemini 2.5 Pro 进行代码任务。

9 致谢

BenGER 由戴姆勒-奔驰基金会作为 TITAN 项目（“司法系统的技术智能转型、自动化和用户导向”）的一部分慷慨资助，并由德国联邦司法部作为联邦司法数字化倡议的一部分在 GSJ 项目（“Generatives Sprachmodell der Justiz”）下资助，该项目是北莱茵-威斯特法伦州和巴伐利亚州司法部、慕尼黑大学和科隆大学之间的合作。

参考文献

[1] Yu Fan, Jingwei Ni, Jakob Merane, Etienne Salimbeni, Yang Tian, Yoan Hermstrüwer, Yinya Huang, Mubashara Akhtar, Florian Geering, Oliver Dreyer, Daniel Brunner, Markus Leippold, Mrinmaya Sachan, Alexander Stremitzer, Christoph Engel, Elliott Ash, and Joel Niklaus. 2025. LEXam: Benchmarking Legal Reasoning on 340 Law Exams. doi:10.48550/arXiv.2505.12864

[2] Neel Guha, Daniel E. Ho, Julian Nyarko, and Christopher Re. 2022. LegalBench: Prototyping a Collaborative Benchmark for Legal Reasoning. arXiv:2209.06120 [cs]

[3] Urs Kramer, Michael Granitzer, and Johann Graf Lambsdorff. 2024. DeepWrite: Annotation and Extraction of Legal Texts. https://extract-annotations.deepwrite.pads.fm.uni-passau.de/

[4] Hiroki Nakayama, Takahiro Kubo, Junya Kamura, Yasufumi Taniguchi, and Xu Liang. 2018. doccano: Text Annotation Tool for Human. https://github.com/doccano/doccano Software available from https://github.com/doccano/doccano.

[5] Maxim Tkachenko, Mikhail Malyuk, Andrey Holmanyuk, and Nikolai Liubimov. 2020-2025. Label Studio: Data labeling software. https://github.com/HumanSignal/label-studio Open source software available from https://github.com/HumanSignal/label-studio.

[6] Gijs van Dijk, Carlos Aguilera, Chris van der Lans, Shashank Chakravarthy, and Sander van Essel. 2022. Lawnotation: A Formal Language for Legal Rules. https://www.lawnotation.org.

本文献翻译自 BenGER 论文，仅供学术交流使用。数学公式由 MathJax 渲染，请确保网络连接。